

# Задание 2. ChIP-seq

## 1. Введение

В ходе данной работы была поставлена задача исследовать изменение genome binding landscape для Foxd3 в процессе ранних этапов развития (от гаструляции, до начала формирования нервного гребня) с помощью данных ChIP-seq. Работа основана на статье [From Pioneer to Repressor: Bimodal foxd3 Activity Dynamically Remodels Neural Crest Regulatory Landscape In Vivo - ScienceDirect](#)

Foxd3 известен как фактор для поддержания мультипотентности и развития нервного гребня, однако был неизвестен механизм его действия. В данной статье авторы хотели выяснить, какие гены оказывают влияние на foxd3, как потеря foxd3 изменяет экспрессию генов, как foxd3 действует на разных этапах развития.

---

Нам доступны данные ChIP-seq для нескольких временных этапов

- 75ep (75% epibody)
- 1-2 ss (1-2 сомита)
- 5-6 ss (5-6 сомитов)
- 14ss (14 сомитов)

В качестве примера, данные 5-6ss уже обработаны, 14ss выделены для семинара, 75ep и 1-2ss - для домашнего задания

---

## Задание

- Самостоятельно проанализировать три стадии (75% epiboly, 1-2ss, 14ss) используя следующий пайплайн
  - BAM QC → ChIP/Input BigWig →  $\log_2(\text{ChIP}/\text{Input})$  → MACS3 peaks → p/q-value → FRIP → heatmap + average profile
- После этого необходимо сравнить 75ep - 1-2ss - 5-6ss - 14ss по
  - числу пиков
  - FRiP
  - силе enrichment
  - pairwise overlap
  - jaccard index
  - stage-specific peaks

Дальше в геномном браузере необходимо показать как минимум три loci

- сильный пик 5-6ss
- область, общая для нескольких стадий
- stage-specific или stage-biased области

В качестве итоге, необходимо ответить на вопрос, как изменяется профиль связывания Foxd3 от гастрюляции к миграции neural crest и какую часть наблюдаемых различий мы можем уверенно считать биологической, а какую нельзя отделить от различий качества ChIP-seq.

## 2. Ход работы

Первоначально было создано окружение для работы:

```
[studfbmf01_27@calc ~]$ micromamba create -n chipseq \
--clone /home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq

[studfbmf01_27@calc ~]$ micromamba activate chipseq
```

Проверено наличие macs3

```
(chipseq) [studfbmf01_27@calc ~]$ which macs3
```

```
• (chipseq) [studfbmf01_27@calc ~]$ which macs3
~/.local/share/mamba/envs/chipseq/bin/macs3
```

После этого была создана нужная для работы структура папок с помощью скрипта:

```
(chipseq) [studfbmf01_27@calc ~]$ bash
/home/STUDY/FBMF/bioinformatics/chipseq/00_setup_student_workspace.sh
```

### 2.1 Стадия 14ss (часть с семинара)

Перед обработкой необходимо посмотреть статистику BAM (для ChIP и Input).

\* Input - данные по хроматину до иммунопреципитации, все остальные шаги обработки были проведены, соответственно Input отображает фоновое распределение ридов)

- ChIP

```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat
data/foxd3_14ss_chip.nuclear.bam
```

```
41553880 + 0 mapped (100.00% : N/A)
41553880 + 0 primary mapped (100.00% : N/A)
41553880 + 0 paired in sequencing
20776940 + 0 read1
```

```
20776940 + 0 read2
41553880 + 0 properly paired (100.00% : N/A)
41553880 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

- 41553880 прочтений суммарно
- Секвенирование парноконцевое (половина read1 - прямые, половина read2 - обратные)
- 100% качество выравнивания - все прочтения выровнены в правильных парах
- Нет ошибок картирования, синглетонов (прочтение без пары) и картирований на другие хромосомы
- Input

```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat
data/foxd3_14ss_input.nuclear.bam
```

```
27794668 + 0 mapped (100.00% : N/A)
27794668 + 0 primary mapped (100.00% : N/A)
27794668 + 0 paired in sequencing
13897334 + 0 read1
13897334 + 0 read2
27794668 + 0 properly paired (100.00% : N/A)
27794668 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

- 27794668 прочтений суммарно
- Парноконцевое секвенирование
- Тоже 100% качество выравнивания пар

Оба BAM имеют одинаковое качество, но Input имеет покрытие примерно в 1.5 раза меньше тестовых данных, в целом этого достаточно.

Теперь мы можем построить покрытие для ChIP и Input ридов

- Мы разбиваем на бины по 10 bp и нормируем на глубину библиотеки (вообще просто надо делать + мы знаем с QC что общее покрытие сильно различается)
- Данные получаем в виде двух файлов bigWig
- Так как задача достаточно ресурсоемкая, то запускаем в виде скрипта через очередь SLURM

```
#!/usr/bin/env bash
```

```
#SBATCH --job-name=bam_coverage
#SBATCH --partition=AMD9554-H200NVL
#SBATCH --gres=gpu:h200nvl:1
#SBATCH --cpus-per-task=4
#SBATCH --mem=128G
#SBATCH --time=2:00:00
#SBATCH --
output=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.log
#SBATCH --
error=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.err
```

```
source ~/.bashrc
```

```
micromamba activate chipseq
```

```
PORT=$((20000 + SLURM_JOB_ID % 20000))
NODE=$(hostname)
WORKDIR=/home/STUDY/FBMF/studfbmf01_27/chipseq_seminar
```

```
cd $WORKDIR
```

```
echo "coverage for chip"
```

```
bamCoverage \
  -b data/foxd3_14ss_chip.nuclear.bam \
  -o results/signal/foxd3_14ss_chip.CPM.bw \
  --normalizeUsing CPM \
  --binSize 10 \
  --numberOfProcessors 4
```

```
echo "coverage for input"
```

```
bamCoverage \
  -b data/foxd3_14ss_input.nuclear.bam \
  -o results/signal/foxd3_14ss_input.CPM.bw \
  --normalizeUsing CPM \
  --binSize 10 \
  --numberOfProcessors 4
```

```
echo "finished"
```

Теперь можно посчитать обогащение (enrichment) по отношению к Input

```
bigwigCompare \
  -b1 results/signal/foxd3_14ss_chip.CPM.bw \
  -b2 results/signal/foxd3_14ss_input.CPM.bw \
```

```
--operation log2 \
--pseudocount 1 \
--binSize 10 \
-o results/signal/foxd3_14ss.log2_IP_Input.bw
```

- Указываем тот же размер бинов, операция log2 значит, что мы считаем логарифм по основанию 2 для отношения  $\text{ChIP}(x) + 1 / \text{Input}(x) + 1$ 
  - +1 нужен чтобы не получить 0
  - если полученное значение больше нуля, то сигнал ChIP выше Input, если меньше нуля, то наоборот

Теперь можно определить участки, где сигнал ChIP статистически превышает ожидаемый фон - peak calling

```
macs3 callpeak \
-t data/foxd3_14ss_chip.nuclear.bam \
-c data/foxd3_14ss_input.nuclear.bam \
-f BAMPE \
-g 1360000000 \
-n foxd3_14ss \
-q 0.01 \
--outdir results/peaks
```

- используем FDR (false discovery rate) = 0.01 - доля пиков, которые мы считаем ложноположительным результатом
- параметр -g эффективный размер генома
- параметр -f определяет формат, BAMPE - BAM file for Paired-End data

Посмотрим, сколько было найдено пиков

```
[studfbmf01_27@calc ~]$ wc -l
chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak
```

```
170 chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak
```

Найдено суммарно 170 пиков.

Рассмотрим структуру файла narrowPeak

```
[studfbmf01_27@calc ~]$ head
chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak
```

```
[studfbmf01_27@calc ~]$ head chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak
NC_007112.7 844066 844303 foxd3_14ss_peak_1 112 . 5.45518 16.2363 11.2721 158
NC_007112.7 2888865 2889138 foxd3_14ss_peak_2 27 . 3.79941 7.02904 2.70006 24
NC_007112.7 38224481 38224863 foxd3_14ss_peak_3 296 . 7.43349 35.4518 29.6614 84
NC_007112.7 52006311 52006785 foxd3_14ss_peak_4 1523 . 17.8532 159.07 152.393 213
```

Файл имеет вид таблицы с следующими столбцами:

- первое поле - хромосома
- второе и третье поле - начальная и конечная позиция пика
- четвертое поле - название (у нас это foxd3\_14ss\_peak{номер пика})
- пятое поле - score (чем больше, тем достовернее)
- шестое поле - ориентация цепи - у нас неприменимо, поэтому стоит точка
- седьмое поле - signalValue - мера enrichment региона
- восьмое поле -  $-\log_{10}(\text{p-value})$
- девятое поле -  $-\log_{10}(\text{q-value})$
- десятое поле - точное положение вершины (summit)

Найдем наиболее значимые пики, отсортировав по  $-\log_{10}(\text{q-value})$  (девятая колонка, сортировка по численным значениям в обратном порядке)

```
[studfbmf01_27@calc ~]$ sort -k9,9nr
chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak | head
```

```
[studfbmf01_27@calc ~]$ sort -k9,9nr chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak | head
NC_007126.7 35583506 35583991 foxd3_14ss_peak_74 3214 . 24.9995 330.35 321.453 230
NC_007114.7 14914162 14914708 foxd3_14ss_peak_9 2804 . 34.6699 287.998 280.494 304
NC_007112.7 52006311 52006785 foxd3_14ss_peak_4 1523 . 17.8532 159.07 152.393 213
NW_003336809.1 1264 1906 foxd3_14ss_peak_149 1480 . 2.99794 154.712 148.07 206
NW_003336809.1 684 949 foxd3_14ss_peak_148 1152 . 3.34538 121.64 115.225 201
NC_007129.7 46370033 46370416 foxd3_14ss_peak_96 935 . 15.2699 99.8794 93.5617 153
NW_003336678.1 17930 18156 foxd3_14ss_peak_140 801 . 3.8773 86.3815 80.1415 43
NC_007129.7 44275947 44276326 foxd3_14ss_peak_95 586 . 12.9962 64.7909 58.6621 196
NC_007115.7 24985710 24985968 foxd3_14ss_peak_11 451 . 8.89114 51.1718 45.1445 121
NC_007134.7 35840142 35840449 foxd3_14ss_peak_108 431 . 8.67428 49.1783 43.1735 175
```

Для самого первого пика (самый значимый)

- местоположение - 35583506-35583991
- signalValue - 24.9995
- $q\text{-value} = 10^{-321.453}$
- $p\text{-value} = 10^{-330.35}$

Теперь найдем FRiP (fraction of reads in peaks) - метрика отношения сигнала к шуму.

$$FRiP = \frac{\text{количество картированных прочтений в области пиков}}{\text{общее число картированных прочтений}}$$

Общее количество ридов

```
(chipseq) [studfbmf01_27@calc ~]$ samtools view -c chipseq_seminar/data/foxd3_14ss_chip.nuclear.bam
41553880
```

Риды, попавшие в области пиков

```
(chipseq) [studfbmf01_27@calc ~]$ samtools view -c -L chipseq_seminar/results/peaks/foxd3_14ss_peaks.narrowPeak chipseq_seminar/data/foxd3_14ss_chip.nuclear.bam 67346
```

$$FRiP = \frac{67346}{41553880} \approx 0.00162 = 1.6 \cdot 10^{-3} (0.16\%)$$

FRiD очень низкий - нужно будет потом сравнить с остальными стадиями

Соберем сигнал вокруг вершин пиков

```
computeMatrix reference-point \
  --referencePoint center \
  -R results/peaks/foxd3_14ss_summits.bed \
  -S results/signal/foxd3_14ss_chip.CPM.bw \
    results/signal/foxd3_14ss_input.CPM.bw \
  -b 2000 \
  -a 2000 \
  --binSize 20 \
  -o results/75ep/figures/foxd3_75ep.matrix.gz
```

В результате получится сжатый файл с матрицей данных, которая показывает значения плотности сигнала вокруг саммитов (вершин) пиков


- по строкам - координаты из файла
- по столбцам - сигнал + метаданные

```
@{"upstream": [2000, 2000], "downstream": [2000, 2000], "body": [0, 0], "bin size": [20, 20], "ref point": ["center", "center"], "verbose": false, "bin avg type": "mean", "missing": 0}
NC_007112.7 844224 844225 NC_007112.7:844224-844225 . . 0.007220 0.000000 0.000000 0.000000 0.021659 0.069789 0.086635 0.043317 0
NC_007112.7 2888889 2888890 NC_007112.7:2888889-2888890 . . 0.093854 0.107090 0.188911 0.193724 0.125139 0.096261 0.085431 0.072195 0
NC_007112.7 38224565 38224566 NC_007112.7:38224565-38224566 . . 0.090244 0.060163 0.042114 0.054147 0.060163 0.072195 0.072195 0
NC_007112.7 52006524 52006525 NC_007112.7:52006524-52006525 . . 0.016846 0.024065 0.019252 0.000000 0.000000 0.000000 0.000000 0
NC_007113.7 814872 814873 NC_007113.7:814872-814873 . . 0.024065 0.021659 0.000000 0.000000 0.002407 0.024065 0.024065 0
NC_007113.7 14005984 14005985 NC_007113.7:14005984-14005985 . . 0.043317 0.012033 0.024065 0.040911 0.040911 0.072195 0.093854 0
NC_007113.7 14675829 14675830 NC_007113.7:14675829-14675830 . . 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0
NC_007113.7 33276248 33276249 NC_007113.7:33276248-33276249 . . 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.021659 0
NC_007114.7 14914466 14914467 NC_007114.7:14914466-14914467 . . 0.000000 0.000000 0.014439 0.048130 0.040911 0.004813 0.000000 0
NC_007115.7 17823552 17823553 NC_007115.7:17823552-17823553 . . 0.000000 0.016846 0.048130 0.060163 0.036098 0.045724 0.024065 0
NC_007115.7 24985831 24985832 NC_007115.7:24985831-24985832 . . 0.049334 0.084228 0.070992 0.046927 0.037301 0.048130 0.022862 0
NC_007115.7 26868690 26868691 NC_007115.7:26868690-26868691 . . 0.096261 0.060163 0.060163 0.036098 0.024065 0.060163 0.144391 0
NC_007115.7 26875269 26875270 NC_007115.7:26875269-26875270 . . 0.294798 0.138375 0.186505 0.275546 0.220196 0.067382 0.046927 0
NC_007115.7 26885471 26885472 NC_007115.7:26885471-26885472 . . 0.072195 0.046927 0.061366 0.099870 0.132358 0.117919 0.095057 0
NC_007115.7 26898526 26898527 NC_007115.7:26898526-26898527 . . 0.031285 0.086635 0.077008 0.026472 0.000000 0.000000 0.000000 0
NC_007115.7 28707876 28707877 NC_007115.7:28707876-28707877 . . 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0
NC_007115.7 28709594 28709595 NC_007115.7:28709594-28709595 . . 0.281562 0.401888 0.324879 0.233432 0.433173 0.471677 0.211773 0
NC_007115.7 36251819 36251820 NC_007115.7:36251819-36251820 . . 0.024065 0.036098 0.024065 0.013236 0.000000 0.000000 0.000000 0
NC_007116.7 448009 448010 NC_007116.7:448009-448010 . . 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0
NC_007116.7 825051 825052 NC_007116.7:825051-825052 . . 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0
NC_007116.7 7302374 7302375 NC_007116.7:7302374-7302375 . . 0.019252 0.000000 0.021659 0.052943 0.062569 0.028878 0.048130 0.052943 0
```


(распаковал и открыл .matrix)

С помощью данной сжатой матрицы можно построить тепловую карту и средний профиль пика (то есть как выглядит enrichment вокруг саммита)

```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ plotHeatmap \
-m results/figures/foxd3_14ss.matrix.gz \
-out results/figures/foxd3_14ss.heatmap.pdf \
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```



```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ plotProfile \
-m results/figures/foxd3_14ss.matrix.gz \
-out results/figures/foxd3_14ss.heatmap.pdf \
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```



Средний профиль представляет из себя усреднение обогащения вокруг саммита всех исследуемых участков генома, по оси X идут координаты (нулевая точка - пик и по 2 kb в обе стороны), по оси Y - сигнал CPM

---

В дальнейшем была проведена обработка по такому же пайплайну данных для стадий 75ер и 1-2ss

(перед этим была изменена структура директорий, чтобы файлы для разных стадий не перемешивались - отдельные подпапки для стадий)

---

## 2.2 1-2ss

### Статистика

- ChIP

```
• (chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat data/1-2ss/foxd3_1-2ss_chip.nuclear.bam
12816614 + 0 in total (QC-passed reads + QC-failed reads)
12816614 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
12816614 + 0 mapped (100.00% : N/A)
12816614 + 0 primary mapped (100.00% : N/A)
12816614 + 0 paired in sequencing
6408307 + 0 read1
6408307 + 0 read2
12816614 + 0 properly paired (100.00% : N/A)
12816614 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

- Input

```

(chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat data/1-2ss/foxd3_1-2ss_input.nuclear.bam
33460348 + 0 in total (QC-passed reads + QC-failed reads)
33460348 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
33460348 + 0 mapped (100.00% : N/A)
33460348 + 0 primary mapped (100.00% : N/A)
33460348 + 0 paired in sequencing
16730174 + 0 read1
16730174 + 0 read2
33460348 + 0 properly paired (100.00% : N/A)
33460348 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
(chipseq) [studfbmf01_27@calc chipseq_seminar]$

```

Интересно, что тут покрытие Input наоборот почти в 3 раза выше

Количество пиков - 80

Для самого значимого пика



- местоположение - 33276062-33276596
- signalValue - 21.2286
- q-value =  $10^{-56.18}$
- p-value =  $10^{-65.27}$

Количество ридов

- всего - 12816614
- в пиках - 1799

$$FRiP = \frac{1799}{12816614} \approx 1.4 \cdot 10^{-4} (0.014\%)$$

Heatmap и усредненный профиль



## 2.3 75ep

### Статистика

- ChIP

```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat data/75ep/foxd3_75ep_chip.nuclear.bam
23863894 + 0 in total (QC-passed reads + QC-failed reads)
23863894 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
23863894 + 0 mapped (100.00% : N/A)
23863894 + 0 primary mapped (100.00% : N/A)
23863894 + 0 paired in sequencing
11931947 + 0 read1
11931947 + 0 read2
23863894 + 0 properly paired (100.00% : N/A)
23863894 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

- Input

```
(chipseq) [studfbmf01_27@calc chipseq_seminar]$ samtools flagstat data/75ep/foxd3_75ep_input.nuclear.bam
39931858 + 0 in total (QC-passed reads + QC-failed reads)
39931858 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
39931858 + 0 mapped (100.00% : N/A)
39931858 + 0 primary mapped (100.00% : N/A)
39931858 + 0 paired in sequencing
19965929 + 0 read1
19965929 + 0 read2
39931858 + 0 properly paired (100.00% : N/A)
39931858 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

Количество пиков - 36

Для самого значимого пика


- местоположение - 33276014-33276551
- signalValue - 21.7013
- q-value =  $10^{-100.05}$
- p-value =  $10^{-109.26}$


Количество рядов

- всего - 23863894
- в пиках - 4101

$$FRiP = \frac{4101}{23863894} \approx 1.7 \cdot 10^{-4} (0.017\%)$$

Heatmap и усредненный профиль





## 2.4 5-6ss

Так как данные для этой стадии уже обработаны, просто посмотрим на результаты

Количество пиков - 839

Для самого значимого пика


- местоположение - 14914145-14914787
- signalValue - 30.9796
- q-value =  $10^{-135.71}$
- p-value =  $10^{-142.95}$

Количество ридов


- всего - 18853396
- в пиках - 44485

$$FRiP = \frac{44485}{18853396} \approx 2.4 \cdot 10^{-3} (0.24\%)$$

Heatmap



Средний профиль



## Результаты

### Сводная таблица

| Stage | Chip alignments | Input alignments | Peaks | FRiP   | max -log10(q-value) |
|-------|-----------------|------------------|-------|--------|---------------------|
| 75ep  | 23863894        | 39931858         | 36    | 1.7E-4 | 100.05              |
| 1-2ss | 12816614        | 33460348         | 80    | 1.4E-4 | 56.18               |
| 5-6ss | -*              | -                | 839   | 2.4E-3 | 135.71              |
| 14ss  | 41553880        | 27794668         | 170   | 1.6E-3 | 321.45              |

\*у нас нет исходных bam файлов для 5-6ss

Больше всего пиков было найдено на стадии 5-6 сомитов - 839, что значительно больше чем на других стадиях. Так же на этой же стадии ChIP enrichment выглядит более выраженным по метрике FRiP - наибольшая часть ридов попала в пики.

Разница в числе пиков очень большая и скорее всего ее нельзя полностью объяснить только биологией, например в целом влияет глубина секвенирования - чем она больше, тем больше чувствительность при peak calling, так же может влиять качество Input (если он слишком маленький, то можем как потерять часть пиков, так и получить ложные) и непосредственно качество выполнения экспериментальной части пайплайна - насколько хорошо была проведена иммунопреципитация

## Попарное сравнение

Проведем сравнение всех возможных пар стадий с помощью инструментов bedtools. Так как хочется сравнить не только просто число пиков и долю общих пиков между стадиями, но и изменение их пространственного распределения, был написан небольшой скрипт

```
#!/usr/bin/env python3

import subprocess
import pandas as pd
```

```

import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from pathlib import Path

peak_files = {
    "75ep": "foxd3_75ep_peaks.narrowPeak",
    "1-2ss": "foxd3_1-2ss_peaks.narrowPeak",
    "5-6ss": "foxd3_5-6ss_peaks.narrowPeak",
    "14ss": "foxd3_14ss_peaks.narrowPeak",
}

BIN_SIZE = 5_000

stages = list(peak_files.keys())

print("Проверяю наличие файлов...")
for stage, fname in peak_files.items():
    path = Path(fname)
    if not path.exists():
        raise FileNotFoundError(f"Файл не найден: {fname}")
    print(f"  ✓ {stage}: {fname} ({path.stat().st_size} bytes)")
print()

def count_lines(filename: str) -> int:
    result = subprocess.run(
        ["wc", "-l", filename],
        capture_output=True, text=True, check=True
    )
    return int(result.stdout.strip().split()[0])

print("Считаю пересечения...")

results = []

for i, stage_a in enumerate(stages):
    for stage_b in stages[i+1:]:
        a = peak_files[stage_a]
        b = peak_files[stage_b]

        n_a = count_lines(a)
        n_b = count_lines(b)

        cmd = ["bedtools", "intersect", "-a", a, "-b", b, "-u"]
        result = subprocess.run(cmd, capture_output=True, text=True,
check=True)
        n_overlap = len(result.stdout.strip().splitlines()) if
result.stdout.strip() else 0

        jaccard_out = subprocess.run(

```

```

        ["bedtools", "jaccard", "-a", a, "-b", b],
        capture_output=True, text=True, check=True
    ).stdout.strip().splitlines()

    jaccard = float(jaccard_out[1].split("\t")[2])

    results.append({
        "Stage_A": stage_a,
        "Stage_B": stage_b,
        "Peaks_A": n_a,
        "Peaks_B": n_b,
        "Overlap": n_overlap,
        "Specific_A": n_a - n_overlap,
        "Specific_B": n_b - n_overlap,
        "Jaccard": round(jaccard, 4)
    })

df_overlap = pd.DataFrame(results)
print("\n===== Таблица пересечений =====")
print(df_overlap.to_string(index=False))
df_overlap.to_csv("peak_overlaps_table.csv", index=False)
print("\nТаблица сохранена: peak_overlaps_table.csv\n")

print("Строю heatmap по координатам...")

all_peaks = "all_peaks_merged.bed"
cmd = (
    f"cat {' '.join(peak_files.values())} | "
    f"cut -f1-3 | sort -k1,1 -k2,2n | bedtools merge -i stdin > {all_peaks}"
)
subprocess.run(cmd, shell=True, check=True)

bins = []
chroms = subprocess.check_output(
    f"cut -f1 {all_peaks} | sort | uniq", shell=True, text=True
).strip().splitlines()

for chrom in chroms:
    coords = subprocess.check_output(
        f"awk -v c={chrom} '$1==c {{print $2\"\\t\"$3}}' {all_peaks}",
        shell=True, text=True
    ).strip().splitlines()

    if not coords:
        continue

    starts = [int(x.split()[0]) for x in coords]
    ends = [int(x.split()[1]) for x in coords]
    chrom_start = min(starts)
    chrom_end = max(ends)

```

```

        for pos in range(chrom_start, chrom_end + BIN_SIZE, BIN_SIZE):
            bins.append(f"{chrom}\t{pos}\t{pos + BIN_SIZE}")

bins_bed = "genome_bins.bed"
with open(bins_bed, "w") as f:
    f.write("\n".join(bins) + "\n")

matrix = []
for stage, peak_file in peak_files.items():
    result = subprocess.run(
        ["bedtools", "coverage", "-a", bins_bed, "-b", peak_file, "-counts"],
        capture_output=True, text=True, check=True
    )
    counts = [int(line.split("\t")[3]) for line in result.stdout.strip().splitlines()]
    matrix.append(counts)

matrix = np.array(matrix)

plt.figure(figsize=(18, 5))
sns.heatmap(
    matrix,
    cmap="YlOrRd",
    yticklabels=stages,
    xticklabels=False,
    cbar_kws={"label": "Number of peaks in bin"}
)
plt.title(f"Foxd3 peaks distribution (bin size = {BIN_SIZE//1000} kb)")
plt.xlabel("Genomic position (binned)")
plt.ylabel("Stage")
plt.tight_layout()
plt.savefig("peaks_genomic_heatmap.png", dpi=200)
plt.savefig("peaks_genomic_heatmap.pdf")
print("Heatmap сохранил: peaks_genomic_heatmap.png / .pdf")

print("Слов presence/absence heatmap...")

union = "union_peaks.bed"
subprocess.run(
    f"cat {' '.join(peak_files.values())} | cut -f1-3 | "
    f"sort -k1,1 -k2,2n | bedtools merge -i stdin > {union}",
    shell=True, check=True
)

presence = []
for stage, peak_file in peak_files.items():
    result = subprocess.run(
        ["bedtools", "intersect", "-a", union, "-b", peak_file, "-c"],

```

```

        capture_output=True, text=True, check=True
    )
    counts = [1 if int(line.split("\t")[3]) > 0 else 0
               for line in result.stdout.strip().splitlines()]
    presence.append(counts)

presence = np.array(presence)

plt.figure(figsize=(14, 4))
sns.heatmap(
    presence,
    cmap="Blues",
    yticklabels=stages,
    xticklabels=False,
    cbar_kws={"label": "Peak present (1) / absent (0)"}
)
plt.title("Presence/absence of Foxd3 peaks across stages")
plt.xlabel("Union peaks (sorted by genomic position)")
plt.ylabel("Stage")
plt.tight_layout()
plt.savefig("peaks_presence_heatmap.png", dpi=200)
print("Presence heatmap сохранён: peaks_presence_heatmap.png")

print("\nГотово!")


```

В результате работы кода мы получим

- матрицу общих пиков
- тепловую карту распределения пиков на разных этапах (количество пиков в бинах и наличие/отсутствие - presence)

| Stage A | Stage B | Peaks A | Peaks B | Overlap | Specific A | Specific B | Jaccard |
|---------|---------|---------|---------|---------|------------|------------|---------|
| 75ep    | 1-2ss   | 36      | 40      | 12      | 24         | 28         | 0.1737  |
| 75ep    | 5-6ss   | 36      | 839     | 22      | 14         | 817        | 0.0227  |
| 75ep    | 14ss    | 36      | 170     | 18      | 18         | 152        | 0.0751  |
| 1-2ss   | 5-6ss   | 40      | 839     | 30      | 10         | 809        | 0.0281  |
| 1-2ss   | 14ss    | 40      | 170     | 12      | 29         | 158        | 0.0426  |
| 5-6ss   | 14ss    | 839     | 170     | 40      | 799        | 130        | 0.0369  |

Карта распределения количества пиков не очень информативна ввиду относительно малого количества пиков в целом, так что лучше рассмотрим карту наличия пиков ChIP в разных областях



Можно заметить следующие закономерности

- Наибольшее количество пиков зарегистрировано для стадии 5-6ss, при этом они распределены по всему геному - есть буквально 1 крупная область без пиков
- Паттерны на разных стадиях значительно отличаются, хотя и прослеживаются пики, общие для разных стадий (при этом не только для последовательно идущих - есть пики, которые остаются с 75ep до 14ss)
  - Наиболее похожими являются стадии 75ep и 1-2ss - мало пиков, высокий индекс Жаккара,
  - Наиболее сильно от всех отличается стадия 5-6s
- Профили распределения пиков по геному для 5-6ss и 14ss практически зеркальны - получается что на этих стадиях foxd3 связывается совершенно с разными областями (об этом говорит и самый низкий индекс Жаккара для последовательно идущих стадий)

При этом отсутствие вызванного пика на другой стадии не доказывает отсутствие связывания foxd3, так как peak calling - пороговый метод, если связывание более слабое или менее стабильное, то мы его не обнаружим (ну, еще плохо обнаруживаются широкие пики)

## Анализ в IGV


После этого можно перейти к анализу в IGV (так как IGV работает локально, скачал все необходимые файлы через SCP)

- геном GRCz11.fa + его индекс (fa.fai)
- аннотация GRCz11.gtf
- bigWig файлы с обогащением для ChIP и Input
- Найденные пики (narrowPeak)
- Score log2\_IP

### 1. Выраженный пик для 5-6ss

```
[studfbmf01_27@calc ~]$ sort -k9,9nr chipseq_seminar/pairwise/foxd3_5-6ss_chip_peaks.narrowPeak | head
NC_007117.7      32206483      32207024      foxd3_5-6ss_chip_peak_211      1637      .      21.1014 172.913 163.701274
NC_007117.7      11011115      110111787     foxd3_5-6ss_chip_peak_88      1357      .      30.8706 112.952 135.713228
```

Возьмем пик 211



Интересно, что этот же пик есть на всех других стадиях, однако на 5-6ss он самый выраженный


- координата - NC\_007117.7:32206484-32207024

## 2. Пик на нескольких стадиях

Посмотрим на пики, которые есть во всех стадиях

```
bedtools intersect -a results/75ep/peaks/foxd3_75ep_peaks.narrowPeak -b results/1-2ss/peaks/foxd3_1-2ss_peaks.narrowPeak | bedtools intersect -a stdin -b results/5-6ss/peaks/foxd3_5-6ss_chip_peaks.narrowPeak | bedtools intersect -a stdin -b results/14ss/peaks/foxd3_14ss_peaks.narrowPeak > common_all.narrowPeak
```

| GNU nano 7.2 |          | common_all.narrowPeak |                    |      |   |         |         |         |     |
|--------------|----------|-----------------------|--------------------|------|---|---------|---------|---------|-----|
| NC_007113.7  | 33276096 | 33276465              | foxd3_75ep_peak_2  | 1000 | . | 21.7013 | 109.261 | 100.05  | 250 |
| NC_007115.7  | 24985734 | 24985968              | foxd3_75ep_peak_7  | 913  | . | 17.5995 | 98.7489 | 91.316  | 121 |
| NC_007117.7  | 32206603 | 32206859              | foxd3_75ep_peak_10 | 590  | . | 6.56514 | 65.8648 | 59.0704 | 161 |
| NC_007127.7  | 7515007  | 7515319               | foxd3_75ep_peak_23 | 469  | . | 11.2879 | 53.4818 | 46.9143 | 151 |
| NC_007129.7  | 44276036 | 44276277              | foxd3_75ep_peak_26 | 118  | . | 5.64393 | 17.5346 | 11.854  | 110 |
| NC_007131.7  | 9427951  | 9428181               | foxd3_75ep_peak_28 | 287  | . | 10.2493 | 34.8713 | 28.7145 | 158 |



Координата - NC\_007113.7:33276015-33276551


При этом пик более выражен для 5-6ss и минимально для 14ss

3. Stage-specific|stage-biased области

Найдем пики, специфичные для стадии 75ep

```
bedtools intersect -a results/75ep/peaks/foxd3_75ep_peaks.narrowPeak -b  
results/1-2ss/peaks/foxd3_1-2ss_peaks.narrowPeak results/5-  
6ss/peaks/foxd3_5-6ss_chip_peaks.narrowPeak  
results/14ss/peaks/foxd3_14ss_peaks.narrowPeak -v > unique_75ep.narrowPeak
```

| GNU nano 7.2 |          |          | unique_75ep.narrowPeak |     |   |         |         |         |     |
|--------------|----------|----------|------------------------|-----|---|---------|---------|---------|-----|
| NC_007118.7  | 28701766 | 28702059 | foxd3_75ep_peak_11     | 107 | . | 6.32402 | 16.3661 | 10.7564 | 184 |
| NC_007123.7  | 14338079 | 14338329 | foxd3_75ep_peak_17     | 36  | . | 4.06816 | 8.70066 | 3.61411 | 43  |
| NC_007126.7  | 29778237 | 29778456 | foxd3_75ep_peak_21     | 99  | . | 5.93715 | 15.4829 | 9.91447 | 83  |
| NC_007126.7  | 42412979 | 42413216 | foxd3_75ep_peak_22     | 50  | . | 4.79753 | 10.3344 | 5.09845 | 133 |
| NC_007134.7  | 3454669  | 3454915  | foxd3_75ep_peak_30     | 147 | . | 6.61411 | 20.5768 | 14.778  | 132 |
| NC_007135.7  | 34111341 | 34111630 | foxd3_75ep_peak_34     | 201 | . | 8.94766 | 26.1014 | 20.1201 | 130 |



Данный пик есть только в 75ep, при этом видно, что возможно есть некоторое связывание еще на стадии 5-6ss, но сигнала не хватило для peak calling

Координата - NC\_007118.7:28701767-28702059

# Форматы файлов

## GTF (Gene Transfer Format)

- Текстовый файл аннотации, содержит координаты генов, транскриптов, экзонов и соответствующие атрибуты. Нужен для отображения аннотации в IGV, мы используем для поиска пересечений пиков ChIP-seq с известными элементами генома  
bigWig
- бинарный сжатый формат для хранения непрерывных сигналов, создается из BAM  
BED (Browser Extensible Data)
- формат для геномных интервалов - хранит хромосому, на которой расположен интервал, его начало и конец + опциональные атрибуты, такие как имя, цепь (+/-) и т.д. Использовался для списков пиков, поиска пересечений через bedtools  
narrowPeak
- расширение над форматом BED, содержит score, fold-enrichment,  $-\log_{10}(p/q)$  и положение вершины (summit), является результатом работы MACS  
peaks.xls
- текстовый файл, содержит название хромосомы, начало и конец пика, расположение саммита,  $-\log_{10}(p/q)$ , fold-enrichment, название пика  
matrix.gz
- сжатая (gzip) матрица сигналов вокруг заданных координат, создаваемая computeMatrix. Используется для построения тепловой карты и среднего профиля пика

## Вывод

- Связывание Foxd3 на разных стадиях сильно отличается - изменяется как количество пиков, так и их распределение по геному (ландшафт связывания). Есть пики, которые сохраняются на протяжении нескольких стадий, есть пики, уникальные для отдельных стадий
- Наиболее выраженным сигнал выглядит на стадии 5-6ss - больше всего пиков, более высокий FRiP score
  - на этапе 5-6ss происходит переключение активности - начало репрессии генов дифференцировки, но по-прежнему активация генов спецификации нервного гребня
- Есть относительно немного пиков, которые стабильны между всеми стадиями, однако достаточно много общих регионов на ранних стадиях
- На поздних этапах профиль связывания сильно перестраивается (много различий в целом между 14ss и 5-6ss, при этом присутствует в некоторой степени зеркальность регионов)
- ChIP-seq показывает только факт взаимодействия с белком, он не позволяет делать никаких выводов о том, какое направление имеет регуляция, насколько

велика функциональная важность сайта (есть ли вообще регуляция и насколько она выражена)

- Для того чтобы можно было проверить функциональный эффект связывания foxd3 нужны дополнительные данные
  - RNAseq - чтобы знать то, как изменяется экспрессия на соответствующих стадиях
  - ATAC-seq|H3K27ac ChIP-seq (в целом ChIP на гистоновые модификации) - посмотреть, чем является сайт + открытость хроматина
  - Еще можно попробовать использовать прямые репортерные конструкции (после определения роли сайта)