

Домашнее задание 1

Выполнил - Басихин Игорь

Введение

Данная работа основана на исследовании влияния загрязнения почвы керосином на состав бактериального сообщества.

Авторы работы поместили образцы почвы в закрытие емкости, обработали их разным количеством керосина а затем отбирали образцы и выделяли ДНК (total DNA)

- На 3, 90, 180 и 360 день

Для анализа использовали V4-V5 вариабельные регионы гена 16S РНК, секвенирование проводилось на Illumina MiSeq в парноконцевом режиме с длиной прочтения 250 bp.

В данном задании было необходимо оценить влияние слабого (5 г керосина/кг почвы) и сильного загрязнителя (26 г/кг) на разнообразие бактериального сообщества по сравнению с контрольными образцами

Ход работы

Так как предполагаемая длина ампликона около 400 нуклеотидов, из-за низкого качества последних нуклеотидов (особенно обратных прочтений) при склейке концов потеряется очень много прочтений. В связи с этим, работа осуществлялась только с прямыми прочтениями.

Предварительно создадим разделы

```
Metagenomic\  
  qza\  
  qzv\  
  fastqc\
```

Задача 1


Запустим fastqc на одном из образцов (SRR17307593_1.fastq)

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ fastqc  
/home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307593_1.  
fastq --outdir fastqc/
```


Рассмотрим статистику:



Per base sequence quality




Per sequence quality scores






Per base sequence content



Per sequence GC content





Overrepresented sequences

Sequence	Count	Percentage	Possible Source
GTGTCAGCCGCCGCGGTAATACAGAGGGTGCGAGCGTTGTTCTCGGAATTAT	205	3.936251920122888	No Hit
GTGCCAGCCGCCGCGGTAATACAGAGGGTGCGAGCGTTGTTCTCGGAATTAT	166	3.1874039938556065	No Hit
GTGTCAGCCGCCGCGGTAATACGAAGGGGGCTAGCGTTGCTCGGAATCAC	114	2.1889400921658986	No Hit
GTGTCAGCCGCCGCGGTAATACAGAGGGTGCAAGCGTTGTTCTCGGAATTAT	104	1.9969278033794162	No Hit
GTGTCAGCCGCCGCGGTAAGACGTAGGGGGCCAGCGTTGTTCTCGGAATTAC	103	1.977726574500768	No Hit
GTGCCAGCCGCCGCGGTAATACGAAGGGGGCTAGCGTTGCTCGGAATCAC	93	1.7857142857142856	No Hit
GTGCCAGCCGCCGCGGTAATACAGAGGGTGCAAGCGTTGTTCTCGGAATTAT	71	1.3632872503840245	No Hit
GTGTCAGCCGCCGCGGTAATACAGAGGGGGCAAGCGTTGTTCTCGGAATTAT	71	1.3632872503840245	No Hit
GTGTCAGCCGCCGCGGTAATACGTAGGCAGCAAGCGTTGTTCTCGGAGTTAC	66	1.2672811059907834	No Hit
GTGTCAGCAGCCGCCGCGGTAATACAGAGGGTGCGAGCGTTGTTCTCGGAATTAT	66	1.2672811059907834	No Hit
GTGTCAGCCGCCGCGGTAATACGTAGGCAGCAAGCGTTGTTCTCGGAATTAC	63	1.2096774193548387	No Hit
GTGCCAGCCGCCGCGGTAAGACGTAGGGGGCCAGCGTTGTTCTCGGAATTAC	63	1.2096774193548387	No Hit
GTGTCAGCCGCCGCGGTAATACGTAGGGGGCCAGCGTTGCTCGGAATTAC	61	1.1712749615975424	No Hit
GTGTCAGCCGCCGCGGTAATACGAAGGGGGCTAGCGTTGTTCTCGGAATTAC	61	1.1712749615975424	No Hit

- Качество последовательностей достаточно приемлемо, к последнему нуклеотиду качество даже 25% перцентиля не падает ниже 30
- При этом все последовательности имеют хорошее среднее качество
- Заметно наличие служебного участка примерно в 15 нуклеотидов
- Из-за того что выделенная ДНК относится к разным видам, закономерно нарушается распределение GC состава (не соответствует нормальному)
- Overpresented последовательности относятся к преобладающим компонентам микробиоты образца

В целом можно сказать, что статистика достаточно типична для метагеномных данных + последовательности обладают хорошим качеством прочтения

Фильтрация + Задача 2

Теперь переведем данные из формата FASTQ в специальный формат для Qiime2 - QZA

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime tools import \
--type 'SampleData[SequencesWithQuality]' \
--input-path
/home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/soil_metadata_for_input.
tsv \
--output-path qza/soil_reads.qza \
--input-format SingleEndFastqManifestPhred33V2
```

- тип в данном случае - одноконцевые прочтения в формате FASTQ, а конфигурационный файл содержит информацию о местоположении файлов с

прочтениями

После того, как мы получим конвертированные данные, можно провести фильтрацию по качеству, фильтрацию химерных последовательностей и исправление ошибок секвенирования

Так как это достаточно ресурсоемкая задача, выполнение было запущено на кластере через очередь SLURM

скрипт run_dada2_hw.sh

```
#!/usr/bin/env bash
```

```
#SBATCH --job-name=dada2_denoise
#SBATCH --partition=AMD9554-H200NVL
#SBATCH --gres=gpu:h200nvl:1
#SBATCH --cpus-per-task=20
#SBATCH --mem=128G
#SBATCH --time=2:00:00
#SBATCH --
output=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.log
#SBATCH --
error=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.err
```

```
source ~/.bashrc
```

```
PORT=$((20000 + SLURM_JOB_ID % 20000))
```

```
NODE=$(hostname)
```

```
WORKDIR=/home/STUDY/FBMF/studfbmf01_27/Personal/Homework/Metagenomic
cd $WORKDIR
```

```
echo "start trimming"
```

```
singularity exec -H /home/STUDY/FBMF/studfbmf01_27/q2home:/home/qiime2 -B
/home/STUDY/FBMF \
--env
MPLCONFIGDIR=/home/STUDY/FBMF/studfbmf01_27/tmp,TMPDIR=/home/STUDY/FBMF/stud
fbmf01_27/tmp ~/qiime2-amplicon-2024.10.sif qiime dada2 denoise-single \
--i-demultiplexed-seqs qza/soil_reads.qza \
--p-trim-left 25 \
--p-trunc-len 200 \
--p-max-ee 3 \
--p-n-threads 20 \
--p-pooling-method "pseudo" \
--p-chimera-method "consensus" \
--p-min-fold-parent-over-abundance 4 \
--o-table qza/soil_ASV_table.qza \
--o-representative-sequences qza/soil_rep_seq.qza \
```

```
--o-denoising-stats qza/soil_reads.dada2.stats.qza
```

```
echo "finished"
```

- Будем обрезать первые 25 нуклеотидов (убираем служебную последовательность) и все нуклеотиды после 200 (избавляемся от конца прочтений с плохим качеством и выравниваем длину)
- Максимальное количество ошибок в прочтении - 3 (на основе качества каждого нуклеотида)
- Для исправления ошибок используются данные сразу из всех образцов

На выходе получаем таблицу с вариантами ампликонов - ASV, список всех встреченных ампликонов и статистику по фильтрации.

Поставим скрипт в очередь

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ sbatch run_dada2_hw.sh
```

Статистика + Задача 3

Посмотрим теперь статистики фильтрации, для этого нужно сделать файл с визуализацией

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime metadata tabulate \
--m-input-file qza/soil_reads.dada2.stats.qza \
--o-visualization qzv/soil_reads.dada2.stats.qzv
```

Скачаем файл soil_reads.dada2.stats.qzv и откроем на сайте <https://view.qiime2.org>

Таблица статистики

sample-id	input	filtered	percentage of input passed filter	denoised	non- chimeric	percentage of input non-chimeric
#q2:types ↓	numeric ↑	numeric ↑	numeric ↑	numeric ↑	numeric ↑	numeric ↑
SRR17307258	26992	26932	99.78	26472	25395	94.08
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307269	10387	10322	99.37	9859	9859	94.92
SRR17307273	23451	23405	99.8	23023	20966	89.4
SRR17307278	24834	24783	99.79	24230	23607	95.06
SRR17307316	10833	10723	98.98	10193	10189	94.06
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307392	25424	25374	99.8	24617	24547	96.55
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307406	22460	22420	99.82	21987	21190	94.35
SRR17307409	29485	29434	99.83	28819	28088	95.26
SRR17307413	9875	9740	98.63	9595	9532	96.53
SRR17307419	24624	24574	99.8	23982	23904	97.08
SRR17307420	9962	9873	99.11	9453	9441	94.77
SRR17307436	9471	9380	99.04	9019	8993	94.95
SRR17307475	45492	45407	99.81	44292	43518	95.66
SRR17307492	22781	22731	99.78	22069	21888	96.08
SRR17307525	31085	31013	99.77	30414	29356	94.44

После всех фильтров остается примерно 90-95 процентов исходных последовательностей:

- В самом маленьком наборе осталось 4809/5128 последовательностей - 93.8%
- В самом большом наборе осталось 43518/45482 последовательностей - 95.7%

По итогу можно сказать, что качество данных достаточно хорошее, так как подавляющее большинство последовательностей осталось.

Классификация

Определим таксономическую принадлежность для каждого варианта ампликона, каждый ампликон будет сравниваться с базой данных GreenGenes.v2 - задача тоже вычислительно сложная, поэтому запустим задачу через SLURM

```
#!/usr/bin/env bash
```

```
#SBATCH --job-name=classify
```

```
#SBATCH --partition=AMD9554-H200NVL
```

```
#SBATCH --gres=gpu:h200nvl:1
```

```

#SBATCH --cpus-per-task=16
#SBATCH --mem=40G
#SBATCH --time=2:00:00
#SBATCH --
output=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.log
#SBATCH --
error=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.err

source ~/.bashrc

PORT=$((20000 + SLURM_JOB_ID % 20000))
NODE=$(hostname)

WORKDIR=/home/STUDY/FBMF/studfbmf01_27/Personal/Homework/Metagenomic
cd $WORKDIR

singularity exec -H /home/STUDY/FBMF/studfbmf01_27/q2home:/home/qiime2 -B
/home/STUDY/FBMF \
--env
MPLCONFIGDIR=/home/STUDY/FBMF/studfbmf01_27/tmp,TMPDIR=/home/STUDY/FBMF/stud
fbmf01_27/tmp ~/qiime2-amplicon-2024.10.sif qiime feature-classifier
classify-sklearn \
--i-classifier
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/2022.10.backbone.v4.nb.sklearn-1.4.2.qza \
--i-reads qza/soil_rep_seq.qza \
--o-classification qza/soil_taxonomy.qza \
--p-n-jobs 16

echo "finished"

```

- gg_2022_10_backbone.v4.nb.qza - готовый классификатор, обученный на V4 регионе всех последовательностей базы данных

Задача 4

Так как для работы мы использовали только прямые прочтения, используемая последовательность, как раз соответствует региону V4, на котором был обучен классификатор (да и если бы использовали парные прочтения, все равно можно было бы использовать так как V4 полностью содержится внутри V4-V5)

Визуализация разнообразия и Задача 5

Для построения используем файл с более подробными метаданными

```

GNU nano 5.6.1 /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/soil_metadata_full.tsv
sample-id      contamination_level  replica_number  day_after_contamination  level_and_time_point
#2-types      categorical         categorical     categorical               categorical
SRR17387316   k0                 r1             d3                       k0_t1
SRR17387649   k0                 r2             d3                       k0_t1
SRR17387644   k0                 r3             d3                       k0_t1
SRR17387666   k0                 r1             d90                      k0_t2
SRR17387610   k0                 r2             d90                      k0_t2
SRR17387475   k0                 r3             d90                      k0_t2
SRR17387392   k0                 r1             d180                     k0_t3
SRR17387419   k0                 r2             d180                     k0_t3
SRR17387492   k0                 r3             d180                     k0_t3
SRR17387436   k0                 r1             d360                     k0_t4
SRR17387380   k0                 r2             d360                     k0_t4
SRR17387593   k0                 r3             d360                     k0_t4
SRR17387269   k5                 r1             d3                       k5_t1


```

```

(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime taxa barplot \
--i-table qza/soil_ASV_table.qza \
--i-taxonomy qza/soil_taxonomy.qza \
--m-metadata-file \
/home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/soil_metadata_full.tsv \
--o-visualization qzv/soil_taxonomy_barplot.qzv

```


Откроем barplot на <https://view.qiime2.org>. Упорядочим график по переменной level_and_time_point.



- При повышении объема загрязнений заметно уменьшается биоразнообразие бактерий в образцах, при этом в случае сильного загрязнения разнообразие снижается критически - для последней временной точки 95% составляют 4 класса, один из них - 92%.
 - При этом чем больше загрязнение, тем сильнее и быстрее снижается разнообразие
- В начальный момент времени состав сообществ для всех трех групп (контроль 5г, 25г) практически идентичен.
- В начальной временной точке самыми частыми для всех групп являются классы
 - Gammaproteobacteria
 - Acidobacteriae
 - Alphaproteobacteria

- В группах с загрязнениями в последней временной точке остаются почти только Gammaproteobacteria - такой результат закономерен, так как среди гаммапротеобактерий есть множество бактерий деструкторов углеводов
- Интересно, что в случае слабого загрязнения, к точке k4 доля гаммапротеобактерий снижается - возможно, если среди них есть бактерии, для которых керосин является субстратом, он просто закончился.

Рассмотрим разнообразие подробнее - на уровне родов (где они были установлены)




Самый частый род в загрязненных образцах - Paraburkholderia - среди его представителей много деструкторов углеводов (и ароматических и алифатических). Соответственно, в среде с углеводородным загрязнением подобные бактерии получают конкурентное преимущество.

α/β -разнообразие и задача 6

Перед расчетом метрик разнообразия необходимо построить филогенетическое дерево из имеющихся ампликонов.

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime phylogeny align-to-tree-mafft-fasttree \
--i-sequences qza/soil_rep_seq.qza \
--o-alignment qza/aligned_soil_rep_seq.qza \
--o-masked-alignment qza/masked_aligned_soil_rep_seq.qza \
--o-tree qza/soil_unrooted_tree.qza \
--o-rooted-tree qza/soil_rooted_tree.qza
```


При желании, данное дерево можно визуализировать, так как пакет empress отсутствует в используемом контейнере, было решено скачать файлы дерева и таксономии и запустить empress локально, как было сделано для задания с семинара




Теперь оценим метрики альфа и бета разнообразия. В качестве глубины секвенирования (необходимо отбирать равное количество прочтений) возьмем размер самого маленького образца.

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime diversity core-metrics-phylogenetic \
--i-phylogeny qza/soil_rooted_tree.qza \
--i-table qza/soil_ASV_table.qza \
--p-sampling-depth 4809 \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/soil_metadata_full.tsv
\
--output-dir soil_core_metrics_results
```


Визуализируем результат для метрики weighted UNIFRAC (файл weighted_unifrac_emperor.qzv)




- Образцы всех трех групп для начальной временной точки локализованы в одной области, что подчеркивает то, что токсический эффект керосина оказывал влияние на структуру сообществ далеко не мгновенно.
- Для контрольной группы местоположение точек меняется мало (кластер вытянутый вдоль оси Axis 2 - есть небольшие фоновые изменения)



- Для слабого загрязнения произошло сильное изменение (по оси Axis 1) за первые 90 дней, при этом потом наблюдается некоторое смещение обратно вдоль этой же оси, что может говорить о том, что происходит частичное восстановление изначального разнообразия (это было видно и по долям классов на barplot)



- Для сильного загрязнения изменения к 90 и 180 дню схожи с слабым, однако с течением времени точки только отдаляются от начального кластера - никакого восстановления не наблюдается, изменения необратимы (по крайней мере в текущем масштабе)




Индекс Шеннона

Посмотрим, как распределен индекс разнообразия образцов в сериях с разным загрязнением

Формула индекса Шеннона:


$$H' = - \sum_{i=1}^S p_i (\ln(p_i))$$

```
(metagenome) [studfbmf01_27@calc Metagenomic]$ qiime diversity alpha-group-  
significance \  
--i-alpha-diversity soil_core_metrics_results/shannon_vector.qza \  
--m-metadata-file  
/home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/soil_single_metadata.tsv  
\  
--o-visualization soil_core_metrics_results/soil_shannon_significance.qzv
```



- В начальной точке значения индекса Шеннона во всех трех группах находятся на одинаково максимальном уровне - около 9.0 - разнообразие внутри образца очень высоко
- В контроле разнообразие немного снижается (изменение индекса с 9 до примерно 8.5) - фоновое изменение
- В образце с слабым загрязнением разнообразие (альфа) снижается до некоторого уровня к 180 дню, который практически сохраняется после, даже наблюдается небольшой рост (представленность видов становится более сбалансированной за счет сокращения численности гаммапротеобактерий)
- В образце с сильным загрязнением разнообразие сильно снижается, для последней временной точки индекс составляет около 3.0

Так же стоит заметить идентичность разнообразия в пределах повторностей. что делает их состоятельными



Таким образом

Добавление загрязнителя негативно сказывается на биоразнообразии сообщества, так как большей части бактерий не удастся выжить или из-за экстремальности самих условий или из-за конкуренции с отдельными видами, способными к метаболизму загрязнителя, которые получают сильное конкурентное преимущество. При этом если количество загрязнения не очень велико, то после его полного расщепления возможно частичное восстановление разнообразия/численности.