

Задание 1 Метагеномы

Выполнил - Басихин Игорь

Введение

Данная работа основана на исследовании "Wild mouse gut microbiota promotes host fitness and improves disease resistance"

В данной работе germ-free мышам переносили либо лабораторную микробиоту, либо микробиоту диких мышей (LabR, WildR соответственно)

В дальнейшем анализировали влияние различий микробиоты на устойчивость к заболеваниям (модель гриппа H1N1 и модель колоректального рака AOM/DSS)

В задании было необходимо сравнить микробиоту между разными группами мышей

- W - wildtype исходная микробиота
- WR - wildtype перенесенная микробиота
- L - лабораторная исходная микробиота
- LR - лабораторная перенесенная микробиота

Ход работы

В рамках подготовки к работе создадим структуру папок для работы

```
metagenomes\  
  qza\  
  qzv\  
  fastqc\  
  multiqc\  
  logs\
```

Также подготовим среду conda|micromamba для работы. К сожалению, установить qiime2 в среду не удалось, поэтому использовался готовый контейнер

```
singularity pull qiime2-amplicon-2024.10.sif  
docker://quay.io/qiime2/amplicon:2024.10
```

Пропишем alias для удобства использования (можно будет непосредственно вызывать qiime)

```
alias qiime="singularity exec -H  
/home/STUDY/FBMF/studfbmf01_27/q2home:/home/qiime2 -B /home/STUDY/FBMF --env
```

```
MPLCONFIGDIR=/home/STUDY/FBMF/studfbmf01_27/tmp,TMPDIR=/home/STUDY/FBMF/studfbmf01_27/tmp ~/qiime2-amplicon-2024.10.sif qiime"
```

Проведем контроль качества

Сначала запустим fastqc для всех файлов образцов, а затем соберем отчеты в один с помощью инструмента multiQC


```
(metagenome) [studfbmf01_27@calc metagenome]$ fastqc  
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/*.fq -o ~/metagenome/fastqc
```

```
(metagenome) [studfbmf01_27@calc metagenome]$ multiqc fastqc/ -o multiqc/
```

```
/// MultiQC v1.35  
  
file_search | Search path: /home/STUDY/FBMF/studfbmf01_27/metagenome/fastqc  
searching |  100% 116/116  
fastqc | Found 58 reports  
write_results | Data : multiqc/multiqc_data  
write_results | Report : multiqc/multiqc_report.html  
multiqc | MultiQC complete
```

Можно заметить следующее:


- Качество прочтений сильно снижается к 210+ основанию - нужно будет провести тримминг




- Failure по Overrepresented sequences, Sequence Duplication Levels. Это ожидаемо - собственно это 16S доминирующих образцов (просто в микробиоте их больше, поэтому и детектируется больше)

FastQC: Overrepresented sequences sample summary


58 bars



sequence	Reports	Occurrences	% of all reads
AGAGCGTTATCCGGATTATTGGGGTTTAAAGGGTGCGTA	29	3 536	1.3128 %
AAGCGTTATCCGGATTACTGGGTGTAAAGGGCGTGTA	29	3 381	1.2553 %
AAGCGTTATCCGGAATTACTGGGTGTAAAGGGAGCGTA	29	3 297	1.2241 %
CACGCTTTCGAGCCTCAACGTCAGTCATCGTCCAGCA	29	2 728	1.0128 %
CACGCTTTCGCGCCTCAGCGTCAGTTGCTGTCCAGCA	29	2 725	1.0117 %
CACGCTTTCGCGCCTCACCGTCAGTTGCCGTCCAGTC	28	2 025	0.7518 %
AAGCGTTGTCCGGATTACTGGGTGTAAAGGGCGTGTA	28	1 645	0.6107 %
CACGCTTTCGCGCCTCAGCGTCAGTTACTGTCCAGCA	28	1 501	0.5573 %
CACGCTTTCGCGCCTCACCGTCAGTTATCGTCCAGTA	28	1 251	0.4645 %
CACGCTTTCGCGCCTCACCGTCAGTTGTCGTCCAGCA	28	1 231	0.4570 %
AAGCGTTATCCGGATTATTGGGTGTAAAGGGCGTGTA	28	1 150	0.4270 %
CACGCTTTCGCGCCTCAGCGTCAGTTAATGTCCAGCA	29	1 076	0.3995 %
CACGCTTTCGAGCCTCAACGTCAGTTACTGTCCAGTA	28	1 017	0.3776 %
AGAGCGTTATCCGGATTACTGGGTGTAAAGGGAGCGTA	29	840	0.3119 %
CACGCTTTCGAGCCTCAACGTCAGTTACAGTCCAGTG	28	777	0.2885 %




- Failure по GC-составу - по GC составу обычно проверяют контаминацию последовательностями других видов, у нас изначально набор разных видов, так что есть несколько пиков а не один




- Failure по Per Base Sequence Content - в начале присутствует адаптерная последовательность



Пример (L1R1)



- Pass для Adapter Content, Sequence Length Distribution, Per sequence quality scores (среднее качество около 35-36)



Загрузка данных

Переведем данные из формата FASTQ в специальный формат для Qiime2 - QZA

- Предварительно необходимо исправить ошибки в файле манифеста - metadata_for_input.tsv. Данный файл содержит пути к файлам по образцам (forward и reverse), однако указаны не те папки (mipt_dbmp_biotechnology) и есть переносы строк (windows) которые могут помешать.

```
(metagenome) [studfbmf01_27@calc ~]sed -e
's|/projects/mipt_dbmp_biotechnology/metagenomes|/home/STUDY/FBMF/bioinforma
tics/metagenomes|g' -e 's|\r||'
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata_for_input.tsv
metagenome/new_metadata_for_input.tsv
```

Теперь загружаем данные с новым манифестом

```
(metagenome) [studfbmf01_27@calc metagenome]$ qiime tools import \
--type 'SampleData[PairedEndSequencesWithQuality]' \
--input-path new_metadata_for_input.tsv \
--output-path qza/mice_reads.qza \
```

```
--input-format PairedEndFastqManifestPhred33V2
```

- Параметры:
 - --type - семантический смысл - данные привязаны к образцам и имеют вид парноконцевых прочтений с указанием качества (fastq)
 - --input-path - путь к файлу с метаданными, в нем хранятся пути к прочтениям
 - --output-path - путь для сохранения результата
 - --input-format - физический формат, в котором хранятся прочтения - fastq с кодировкой качества Phred33 + что мы передаем не сами файлы а манифест с указанием путей, v2 - вторая версия формата


Теперь можно посмотреть статистику сырых прочтений через qiime demux summarize

```
(metagenome) [studfbmf01_27@calc metagenome]$ qiime demux summarize \  
--i-data qza/mice_reads.qza \  
--o-visualization qzv/mice_reads.qzv
```


Откроем получившийся QZV файл с помощью <https://view.qiime2.org>

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Forward Reads Frequency Histogram




Reverse Reads Frequency Histogram



[Download as PDF](#)

В разных образцах содержится очень разное количество прочтений - от 2138 до 6394 пар (парноконцевые прочтения)

Более интересно не распределение по частотам, а interactive quality plot, так как его можно использовать для расчета тримминга при предобработке.



Фильтрация и сборка ампликонов

- Риды имеют длину 250 bp
- Минимальный overlap для сборки - 12 bp
- Ампликон имеет длину около 291 bp (смотрим участок V4)

Будем удалять

- 10 bp в начале (trim) - служебная последовательность
- порог по качеству - решил смотреть по 25th перцентилю, так как например медиана для forward не опускается ниже Q30 хотя последние позиции имеют уже достаточно низкое качество
 - forward - отсечка по 220
 - reverse - отсечка по 180

Проверим перекрытие

$$(220 - 10) + (160 - 10) = 210 + 150 = 360 > 291 + 12$$

Так как задача вычислительно затратная, запустим скрипт через SLURM

```
#!/usr/bin/env bash
```

```
#SBATCH --job-name=dada2_denoise
#SBATCH --partition=AMD9554-H200NVL
#SBATCH --gres=gpu:h200nvl:1
#SBATCH --cpus-per-task=4
#SBATCH --mem=128G
#SBATCH --time=2:00:00
#SBATCH --
output=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.log
#SBATCH --
error=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.err
```

```
source ~/.bashrc
```

```

PORT=$((20000 + SLURM_JOB_ID % 20000))

NODE=$(hostname)

WORKDIR=/home/STUDY/FBMF/studfbmf01_27/metagenome

cd $WORKDIR

echo "start trimming"

singularity exec -H /home/STUDY/FBMF/studfbmf01_27/q2home:/home/qiime2 -B
/home/STUDY/FBMF \
--env
MPLCONFIGDIR=/home/STUDY/FBMF/studfbmf01_27/tmp,TMPDIR=/home/STUDY/FBMF/stud
fbmf01_27/tmp ~/qiime2-amplicon-2024.10.sif qiime dada2 denoise-paired \
--i-demultiplexed-seqs qza/mice_reads.qza \
--p-trim-left-f      10 \
--p-trim-left-r      10 \
--p-trunc-len-f      220 \
--p-trunc-len-r      180 \
--p-n-threads        6 \
--o-table qza/mice_ASV_table.qza \
--o-representative-sequences qza/mice_rep_seq.qza \
--o-denoising-stats qza/mice_reads.dada2.stats.qza

echo "finished"

```

Для получения статистики по результату работы dada2 можно воспользоваться несколькими инструментами

1. metadata tabulate

```

(metagenome) [studfbmf01_27@calc ~]$ qiime metadata tabulate \
--m-input-file metagenome/qza/mice_reads.dada2.stats.qza \
--o-visualization metagenome/qzv/mice_reads.dada2.stats.qzv

```

sample-id	input	filtered	percentage of input passed filter				denoised	merged	percentage of input merged	non-chimeric	percentage of input
#q2:types	numeric	numeric	numeric	numeric	numeric	numeric	numeric				
L1	3773	3189	84.52	3073	2730	72.36	2703	71.64			
L2	3669	3034	82.69	2899	2533	69.04	2533	69.04			
L3	5346	4577	85.62	4402	3709	69.38	3583	67.02			
L4	3836	3104	80.92	2976	2629	68.53	2568	66.94			
L5	3311	2680	80.94	2554	2207	66.66	2168	65.48			
L6	4572	3744	81.89	3588	3216	70.34	3195	69.88			
L7	4536	3763	82.96	3617	3220	70.99	3181	70.13			
L8	3498	2783	79.56	2648	2434	69.58	2434	69.58			
LR1	5047	4552	90.19	4387	3971	78.68	3971	78.68			
LR2	6394	5726	89.55	5600	4913	76.84	4858	75.98			
LR3	5753	5075	88.21	4883	4217	73.3	4217	73.3			
LR4	6062	5346	88.19	5181	4580	75.55	4552	75.09			
LR5	6056	5294	87.42	5155	4721	77.96	4721	77.96			
LR6	5855	5128	87.58	5004	4519	77.18	4519	77.18			
LR7	5191	4622	89.04	4458	4124	79.45	4124	79.45			
W1	2138	1725	80.68	1606	1417	66.28	1380	64.55			
W2	3714	2840	76.47	2697	2414	65	2348	63.22			
W3	3211	2782	86.64	2665	2455	76.46	2317	72.16			
W4	3619	2988	82.56	2847	2470	68.25	2447	67.62			
W5	4301	3452	80.26	3261	2834	65.89	2715	63.12			
W6	5016	3675	73.27	3472	3083	61.46	3032	60.45			
W7	3501	2757	78.75	2656	2456	70.15	2319	66.24			

Можно заметить, что при фильтрации осталось от 73 до 90 процентов последовательностей, 60-75 процентов осталось после удаления шума и слияний, и примерно все из них попали в финальный выход (нехимерные последовательности)

- В самом большом по финальному количеству - 4858 прочтений (75.98%) - LR2
- В самом малом по финальному количеству - 1380 прочтений (64.55%) W1

В целом качество последовательностей оказалось очень хорошим (в том числе правильно была проведена предобработка)

2. feature-table summarize

```
(metagenome) [studfbmf01_27@calc ~]$ qiime feature-table summarize \
--i-table metagenome/qza/mice_ASV_table.qza \
--o-visualization metagenome/qzv/mice_ASV_table.qzv \
--m-sample-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv
```

Table summary


Summary Statistic	Value
Number of samples	29
Number of features	512
Total frequency	96 229

Frequency per sample

	Frequency
Minimum frequency	1 380
1st quartile	2 533
Median frequency	3 583
3rd quartile	3 881
Maximum frequency	4 858
Mean frequency	3 318,2

Найден 512 фичей, с медианной встречаемостью 48 и максимальной 5045 (фича встретилась в 5045 последовательностях семплов)

	Frequency
Minimum frequency	2
1st quartile	18
Median frequency	48
3rd quartile	156,5
Maximum frequency	5 045
Mean frequency	187,9



3. feature-table tabulate-seqs

```
(metagenome) [studfbmf01_27@calc ~]$ qiime feature-table tabulate-seqs \
--i-data metagenome/qza/mice_rep_seq.qza \
--o-visualization metagenome/qzv/rep_seqs.qzv
```

Просто таблица последовательностей фичей

Sequence Length Statistics

Download sequence-length statistics as a TSV

Sequence Count	Min Length	Max Length	Mean Length	Range	Standard Deviation
512	232	234	232.87	2	0.41

Seven-Number Summary of Sequence Lengths

Download seven-number summary as a TSV

Percentile:	2%	9%	25%	50%	75%	91%	98%
Length* (nts):	232	232	233	233	233	233	234

*Values rounded down to nearest whole number.

Sequence Table

To BLAST a sequence against the NCBI nt database, click the sequence and then click the *View report* button on the resulting page.

Download your sequences as a raw FASTA file

Click on a Column header to sort the table.

Feature ID ▼	Sequence
ffe26a8fc3269e7182f24f0b7d0c3156	GCAAGCGTTATCCGGATTACTGGGTGTAAGGGGAGCGTAGACGGCGAAGAAAGTCTGAAGTGAAAGCCCGCGGCTCAACCGCGG
fd2eb4325a76eae04fa83458f1acd43	GCGAGCGTTATCCGGATTATTGGGTTTAAAGGGTGCGTAGGCGGGCTGTTAAGTCAGCGGTCAAATGTCGGGGCTCAACCCCGG
fcf2bd49fcc8fe312b8c5b7e8f1b279	GCAAGCGTTATCCGGATTACTGGGTGTAAGGGGCGGTAGGCGGGACTGCAAGTCAGATGTGAAAACCATGGGCTCAACCCATG
fcd52e6831e3ea1230fdc14b3620766f	CCGAGCGTTATCCGGATTATTGGGTTTAAAGGGTGCGTAGGCGGTTTGATAAGTTAGAGGTGAAATGTCGGGGCTCAACCCCGA

Таксономия

Присвоим получившемуся набору ASV таксономию с помощью предобученного байесовского классификатора.

```
#!/usr/bin/env bash
```

```
#SBATCH --job-name=classify
#SBATCH --partition=AMD9554-H200NVL
#SBATCH --gres=gpu:h200nvl:1
#SBATCH --cpus-per-task=8
#SBATCH --mem=128G
#SBATCH --time=2:00:00
#SBATCH --
```

```

output=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.log
#SBATCH --
error=/home/STUDY/FBMF/studfbmf01_27/slurm_logs/jupyter_scvi_%j.err

source ~/.bashrc

PORT=$((20000 + SLURM_JOB_ID % 20000))
NODE=$(hostname)

WORKDIR=/home/STUDY/FBMF/studfbmf01_27/metagenome
cd $WORKDIR

singularity exec -H /home/STUDY/FBMF/studfbmf01_27/q2home:/home/qiime2 -B
/home/STUDY/FBMF \
--env
MPLCONFIGDIR=/home/STUDY/FBMF/studfbmf01_27/tmp,TMPDIR=/home/STUDY/FBMF/stud
fbmf01_27/tmp ~/qiime2-amplicon-2024.10.sif qiime feature-classifier
classify-sklearn \
--i-classifier
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/2022.10.backbone.v4.nb.skle
arn-1.4.2.qza \
--p-n-jobs      8 \
--i-reads       qza/mice_rep_seq.qza \
--o-classification qza/mice_taxonomy.qza

echo "finished"

```

Превратим результат классификации в отчет .qzv

```

[studfbmf01_27@calc ~]$ qiime metadata tabulate \
--m-input-file metagenome/qza/mice_taxonomy.qza \
--o-visualization metagenome/qzv/mice_taxonomy.qzv

```

Feature ID #q2:types	Taxon categorical	Confidence categorical
fc9e84f398ae703d9c40f5e0c0c3dd2f	d__Bacteria; p__Deferribacterota; c__Deferribacteres; o__Deferribacterales; f__Mucispirillaceae; g__Mucispirillum; s__Mucispirillum schaedleri	1.0
507df0d2d1ca79727be75216b04f4270	d__Bacteria; p__Cyanobacteria; c__Vampirovibrionia; o__Gastranaerophilales; f__Gastranaerophilaceae	0.999999999999996
8149512c5b8c724167152c5879e264c8	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__TANB77; f__CAG-508	0.9999999999981555
5e00586966fa601d73c38dff4c834a76	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Bacteroidaceae; g__Bacteroides_H	0.9999999999964588
df23b0c1e101230767f3ea73fab1d27e	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae	0.9999999999953489
148a980b8d9d30c83e111a5f8c7b6287	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Bacteroidaceae; g__Bacteroides_H	0.9999999999916461
8774ff96bec7ebfefe8a8647f32d6aa2	d__Bacteria; p__Firmicutes_B_370539; c__Peptococcia; o__Peptococcales; f__Peptococcaceae_369362; g__Peptococcus; s__Peptococcus niger	0.999999999870397
52763d613745cf06ebcd22d86be7ae5b	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Bacteroidaceae; g__Bacteroides_H	0.9999999999867756
3b0d2735bac1632117ae06ec84430de7	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483; o__TANB77; f__CAG-508	0.9999999999850554
4bd94807436592e5694934e65dc9f4b5	d__Bacteria	0.999999999823915

Можно заметить набор идентифицированных таксонов, при этом разные фици могут быть соотнесены с таксонами разного порядка.

Например, есть feature fc9e84f398ae703d9c40f5e0c0c3dd2f идентифицированная до вида (*Mucispirillum schaedleri*), есть feature 4bd94807436592e5694934e65dc9f4b5, не отнесенная вообще ни к какому таксону ниже Bacteria.

Среди таксонов с наибольшей уверенностью можно заметить кластридий, Bacteroida, различных гамма-протеобактерий.

При этом в целом уверенность классификации составляет 0.94-0.99

Для удобства стоит визуализировать полученную таксономию

```
[studfbmf01_27@calc ~]$ qiime taxa barplot \
--i-table metagenome/qza/mice_ASV_table.qza \
--i-taxonomy metagenome/qza/mice_taxonomy.qza \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv \
--o-visualization metagenome/qzv/mice_taxonomy_barplot.qzv
```

Почему то taxa barplot не понравились метаданные, подставил metadata_for_input (без группировки, на зато запустилось, при этом остальные команды с metadata.tsv работают)


There was an issue with loading the file as metadata:

Metadata file path doesn't exist, or the path points to something other than a file. Please check that the path exists, has read permissions, and points to a regular file (not a directory):

There may be more errors present in the metadata file. To get a full report, sample/feature metadata files can be validated with Keemei: <https://keemei.qiime2.org>

Find details on QIIME 2 metadata requirements here: <https://docs.qiime2.org/2024.10/tutorials/metadata/>

Сравним микробиоту в разных образцах (ограничимся level 3 - класс)



Теперь можно сравнить микробиоту в разных образцах

Для L и LR (мыши с лабораторной микрофлорой) состав микрофлоры практически одинаков - 75-85% составляют Clostridia, дальше по убыванию идут Bacteroida, Deferribacteres, Bacilli

- В целом микрофлора достаточно бедная, при этом представлена в основном клостридиями, среди которых много патогенных и условно-патогенных бактерий

Для W и WR ситуация значительно отличается

- Доля Clostridia значительно меньше - 45% для W (мыши с изначально wild-type микрофлорой) и 55-60% для WR (мыши с пересаженной микрофлорой)
- Начинают встречаться другие таксоны, такие как Campylobacteria, Desulfobacterionia, Gammaproteobacteria, Vampirovibrionia
- Для WR состав микрофлоры выглядит чуть менее разнообразным и сбалансированным

Теперь построим филогенетическое дерево и визуализируем его

```
[studfbmf01_27@calc mice_tree]$ qiime phylogeny align-to-tree-mafft-fasttree \
--i-sequences metagenome/qza/mice_rep_seq.qza \
--o-alignment metagenome/qza/aligned_mice_rep_seq.qza \
--o-masked-alignment metagenome/qza/masked_aligned_mice_rep_seq.qza \
--o-tree metagenome/qza/mice_unrooted_tree.qza \
--o-rooted-tree metagenome/qza/mice_rooted_tree.qza
```


Т.к плагина empress в установленном контейнере нет (и поставить его не дает конфликт зависимостей), я экспортировал таксономию и дерево и собрал визуализацию в empress локально

```
(bio_advanced) teviii@DOOMULTHOME:~$ empress tree-plot \
-t ~/Personal/tree/mice_rooted_tree.nwk \
-fm ~/Personal/tree/mice_taxonomy.tsv \
-o ~/Personal/tree/
```

Для просмотра сгенерированного дерева запустил локальный сервер и открыл страницу в браузере

```
(bio_advanced) teviii@DOOMULTHOME:~/Personal/tree/out$ python -m http.server
8801
```

Level 3	
	d__Bacteria; p__Bacteroidota; c__Bacteroidia
	d__Bacteria; p__Campylobacterota; c__Campylobacteria
	d__Bacteria; p__Cyanobacteria; c__Vampirovibrionia
	d__Bacteria; p__Deferribacterota; c__Deferribacteres
	d__Bacteria; p__Desulfobacterota_I; c__Desulfovibrionia
	d__Bacteria; p__Firmicutes_A; c__Clostridia_258483
	d__Bacteria; p__Firmicutes_A; Unspecified
	d__Bacteria; p__Firmicutes_B_370539; c__Dehalobacteriia
	d__Bacteria; p__Firmicutes_B_370539; c__Peptococcia
	d__Bacteria; p__Firmicutes_D; c__Bacilli
	d__Bacteria; p__Proteobacteria; c__Alphaproteobacteria
	d__Bacteria; p__Proteobacteria; c__Gammaproteobacteria
	d__Bacteria; p__Verrucomicrobiota; c__Verrucomicrobiae
	d__Bacteria; Unspecified; Unspecified



Разнообразие

Теперь рассмотрим альфа и бета разнообразие (первое описывает, насколько разнообразна микробиота внутри одного образца, вторая - насколько микробиоты двух разных образцов отличаются друг от друга)

В качестве минимального количества прочтений (sampling depth) возьмем 2000


```
[studfbmf01_27@calc metagenome]$ qiime diversity core-metrics-phylogenetic \
--i-phylogeny qza/mice_rooted_tree.qza \
```

```
--i-table qza/mice_ASV_table.qza \
--p-sampling-depth 2000 \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv \
--output-dir alpha-beta/mice_core_metrics_result
```

Посмотрим на статистики альфа-разнообразия

- Индекс Шеннона

```
[studfbmf01_27@calc metagenome]$ qiime diversity alpha-group-significance \
--i-alpha-diversity alpha-beta/mice_core_metrics_result/shannon_vector.qza \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv \
--o-visualization qzv/mice_shannon_significance.qzv
```




У мышей, которым не прививали микрофлору (доноры), индекс Шеннона ниже - 5.2 у лабораторных и 4.8 у диких (при этом у диких больше всего разброс). У мышей с привитой микрофлорой, наоборот, индекс Шеннона высокий - около 5.8.

Согласно критерию Краскела-Уоллиса, результаты попарных сравнений показывают, что различия в медианных значениях значимы для пар виды донор-привитый, но не значимы внутри групп (то есть в парах L-W и LR-WR).


Не очень понятно, почему индекс низкий для W, можно посмотреть на равномерность Пиелу и количество фичей

- observed features



несколько выше для мышей с привитой микрофлорой, при этом для wildtype и лабораторной микрофлоры отличий нет
(L-W - $q=0.698$, LR-WR - $q=0.189$)

- равномерность Пиелу




У диких мышей сильно менее сбалансированная микробиота, при этом даже для мышей WR значение равномерности сопоставимое с L и LR - причина низкого значения индекса Шеннона

Рассмотрим бета-разнообразие

- weighted unifrac

```
[studfbmf01_27@calc metagenome]$ qiime diversity beta-group-significance \
--i-distance-matrix alpha-
beta/mice_core_metrics_result/weighted_unifrac_distance_matrix.qza \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv \
--m-metadata-column group \
--p-method permanova --p-pairwise \
```

```
--o-visualization qzv/mice_weighted_unifrac_permanova.qzv
```



Видим 4 кластера, соответствующие четырем группам образцов, при этом кластер для W мышей (донор, wild-type) очень разреженный (до этого виел)

Pairwise permanova results

[Download CSV](#)

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
L	LR	15	999	6.365926	0.001	0.001
	W	14	999	28.157047	0.001	0.001
	WR	15	999	29.308763	0.001	0.001
LR	W	13	999	26.927320	0.001	0.001
	WR	14	999	26.804515	0.001	0.001
W	WR	13	999	12.471065	0.001	0.001

PERMANOVA по weighted unifrac дает, что все попарные сравнения значимы, однако в случае пар донор-соответствующий акцептор различия чуть менее выраженные судя по pseudo-F

- L-WR, L-W, LR-W, LR-WR - везде 26-29
- W-WR - 12.5
- L-LR - 6.4

Weighted unifrac учитывает относительное обилие и филогенетическое сходство, получается, что все группы имеют достаточно уникальную структуру для каждого случая


Так как ранее по К-У для индекса Шеннона пары L-W и LR-WR были схожи, то теперь видно что они различаются, но не просто разнообразием, а разными доминирующими

группами

- Еще можно рассмотреть unweighted unifracs

```
[studfbmf01_27@calc metagenome]$ qiime diversity beta-group-significance \
--i-distance-matrix alpha-
beta/mice_core_metrics_result/unweighted_unifrac_distance_matrix.qza \
--m-metadata-file
/home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata.tsv \
--m-metadata-column group \
--p-method permanova --p-pairwise \
--o-visualization qzv/mice_unweighted_unifrac_permanova.qzv
```

В данном случае не учитывается численность, только наличие таксонов в образце



Тут группы с лабораторной микробиотой и с дикой сливаются в 2 кластера

Pairwise permanova results

[Download CSV](#)

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
L	LR	15	999	3.767278	0.001	0.0012
	W	14	999	11.989751	0.001	0.0012
	WR	15	999	23.711117	0.001	0.0012
LR	W	13	999	12.206636	0.001	0.0012
	WR	14	999	21.929315	0.001	0.0012
W	WR	13	999	5.902494	0.002	0.0020

- L и LR, W и WR - слабые различия, то есть изменялось главным образом соотношение таксонов, а не их набор

Выводы

1. Разнообразие для лабораторной и дикой микробиоты сопоставимо (если не ограничиваться уровнем таксонов достаточно высокого порядка, а смотреть по ASV), при этом в исходной дикой микробиоте есть сильный перекоп в пользу доминантных составляющих (поэтому ниже индекс Шеннона)
2. На уровне классов структура лабораторной и дикой микробиоты отличается достаточно сильно, есть таксоны, представленные у L(LR) мышей и не представленные у W(WR) и наоборот, это показывает как сам набор определенных таксонов, так и бета-разнообразие
3. Разнообразие между L и LR мало - лабораторная микробиота приживается хорошо, сохраняя изначальный состав и структуру
4. Дикая микробиота приживается хуже, при этом можно заметить, что изменяется не качественный набор таксонов, а баланс (данный тезис в целом верен и для лабораторной микробиоты)

Везде работаем с ASV - DADA2 строит модель секвенирования и оценивает, насколько вероятно, что редкая последовательность появилась в результате ошибок прочтения более частой (либо это действительно другой вариант)

При этом в статье использовали подход с OTU

16S rRNA gene compositional analysis

The 16S rRNA gene pipeline data incorporates phylogenetic and alignment-based approaches to maximize data resolution (Buffington et al., 2016; Viladomiu et al., 2017). The 16S rRNA gene read pairs were demultiplexed based on the unique molecular barcodes, and reads were merged using an 8 bp seed, 0 mismatches over a 50bp overlap and an expected error filter of 0.05 with USEARCH v7.0.1090 (Edgar, 2013). 16S rRNA gene sequences were clustered into Operational Taxonomic Units (OTUs) at a similarity cutoff value of 97% using the UPARSE algorithm. OTUs were mapped at 97% sequence identity to an optimized version of the SILVA Database (version 128, <https://www.arb-silva.de/documentation/release-128/>) (Quast et al., 2013) containing only the 16S v4 region to determine taxonomies. Abundances were recovered by mapping the demultiplexed reads to the UPARSE OTUs. A rarefied OTU table from the output files generated in the previous two steps was used for downstream analyses using a visualization toolkit also developed at the CMMR named ATIMA (*Anile Toolkit for Incisive Microbial Analyses*).